

Resumo do artigo: Review of deep learning: concepts, CNN architectures, challenges, applications, future directions. (Laith Alzubaidi, Jinglan Zhang, Amjad J. Humaidi, Ayad Al-Dujaili, Ye Duan, Omran Al-Shamma, J. Santamaría, Mohammed A. Fadhel, Muthana Al-Amidie & Laith Farhan)

Aluno: Laís Santos Gonçalves

De forma geral o artigo mostra a o avanço da deep learning (DL) frente ao aprendizado de máquina (ML) e contribui para mostrar uma abordagem mais holística dos conceitos e aplicações para melhor uso da ferramenta. Nesse resumo iremos focar no tópico “Challenges (limitations) of deep learning and alternate solutions”. O uso da deep learning encontra alguns desafios, como:

Quantidade de dados; é necessária uma alta gama de dados para ter um bom modelo. Quando não se tem essa grande quantidade, existem três métodos disponíveis. O “Transfer-Learning” consiste em utilizar um modelo pré-treinado de uma tarefa específica e reutilizá-lo como ponto de partida na nova tarefa, então esses dados ajudam no aprimoramento do novo modelo. Outra técnica é usar o modelo pré-treinado, mas fazer um ajuste fino de duas camadas ou mesmo de uma camada finais com base nos dados originais limitados. O “Data Augmentation” que seria o aumento de dados, fazendo rotações, espelhamento e translação com os dados originais, mas é importante ter cuidado ao usar essa técnica para não descaracterizar os dados. E o “Simulated Data” é a criação de simuladores para aumentar o número de dados do conjunto de treinamento. **Dados desequilibrados;** dados biológicos geralmente tem mais dados negativos do que positivos isso pode levar a um resultado errado ao treinar o modelo. Para isso existem algumas alternativas, usar métricas de avaliação corretas, como a área sob a curva (AUC), para garantir que o modelo tenha boa performance em todas as classes, tanto pequenas quanto grandes. Utilizar a perda ponderada na entropia cruzada, garantindo que o modelo trate adequadamente as classes menores. Durante o treinamento do modelo, é possível realizar amostragem (down-sampling) das classes grandes ou replicação (up-sampling) das classes pequenas para balancear os dados. Construir modelos para cada nível hierárquico, pois os sistemas biológicos frequentemente têm espaços de rótulos hierárquicos. **Interpretação dos dados;** os modelos de DL são difíceis de interpretar, para isso pode-se usar a técnica de perturbação e a técnica baseada em retropropagação, assim conseguimos confiar mais nos resultados dos modelos. **A escala da incerteza;** é a necessidade de estimar a confiabilidade das previsões feitas por modelos de deep learning, para resolver esse problema tem-se a saída softmax

combinadas com técnicas Binning Bayesiano em Quantis (BBQ), regressão isotônica, binning de histograma e a escala de Platt. E também uma técnica recente é a escala de temperatura. Isso ajudará a confiar mais quando é essencial ter essa confiabilidade. **Esquecimento catastrófico;** significa a incapacidade de um modelo acrescentar uma classe nova sem esquecer o resto das classificações, ou seja, incapaz de incorporar novas informações sem interferir nas informações aprendidas anteriormente. Existem três técnicas que ajudam a resolver esse problema, que são: Elastic Weight Consolidation (EWC), Incremental Classifier and Representation Learning (iCaRL) e Sistemas de aprendizagem de memória dupla.

Tamanho do modelo; quando o modelo é extensivo e tem-se poder computacional limitado, pode-se remover os parâmetros redundantes, passar o conhecimento de um modelo pré treinado para outro modelo menor, compactação de filtros de convolução ou comprimir os parâmetros dos modelos usando técnica de fatoração de baixa classificação. **Sobreajuste;** é o problema da alta capacidade de aprendizagem dos modelos no treinamento e que pode levar a uma performance reduzida em dados de teste. Para combater tem a técnica de redução de pesos, normalização de lote e abandono, isso incentiva o modelo a ficar pequeno e reduzir a complexidade do modelo. A técnica de introduzir variações nos dados de treinamento como por exemplo, rotações e deslocamentos. Isso ajuda o modelo a reduzir a memorização. **Gradiente desaparecido;** é quando os gradientes ficam cada vez menores durante o treinamento, que pode levar a parada do treinamento ou a diminuição da precisão dele. Isso pode ser ajustado com o uso de funções de ativação ReLU ou com GPUs rápidos que podem lidar com redes neurais profundas. **Gradiente explosivo;** é quando existe uma grande quantidade de erro acumulado durante a retropropagação nas redes neurais isso leva a atualizações nos pesos da rede que leva o sistema a ficar instável. Isso pode levar a valores de pesos enormes que podem se transformar em valores não numéricos NAN. Duas soluções são o uso de técnicas de regularização de peso e a revisão da arquitetura da rede neural. **Subespecificação;** é um problema que quando aplicados em situações do mundo real, como nível computacional e processamento de linguagem natural. Quando existe pequenas alterações nos dados, os resultados podem ser inesperados. Para solucionar esse problema precisa de desenvolvimento de testes de resistência para avaliar o desempenho do modelo em situações reais e identificar possíveis falhas. Porém projetar esses testes de forma abrangente representa um desafio significativo.